



Redes Neuronales Informadas por Física (PINNs) para la


simulación y optimización del transporte de hidrógeno en polímeros

Juan C. Vega Ms

INVESTIGADOR PRINCIPAL



Henry Arguello, PhD - UIS

Yesid P. Goyes, Ms - UIS



Deep Learning and Computational Imaging

Professor Henry Arguello






Universidad Industrial de Santander
Escuela de Ingeniería de Sistemas e Informática
Bucaramanga, Colombia



Universidad
Industrial de
Santander




Research areas



Computational Imaging



Deep Learning for Inverse Problems



Areas of Impact:



Interdisciplinarity

Computer Science



Electronic Engineering




Physics



Math



Geology



Industrial Engineering



Electrical and Energy Engineering



Applied Maths







Introducción

Aplicación de PINNs en la optimización del transporte de hidrógeno en polímeros

Las **Redes Neuronales Informadas por Física (PINNs)** se presentan como una solución innovadora para simular y optimizar el transporte de hidrógeno en polímeros. Estas redes integran leyes físicas en su entrenamiento, lo que permite abordar problemas complejos de difusión y permeabilidad, cruciales para el desarrollo de tecnologías de energía limpia.






Arquitecturas Avanzadas en DL


Las arquitecturas modernas de DL permiten modelar sistemas complejos y constituyen la base de redes avanzadas como las PINNs

Cada arquitectura está diseñada para aprender diferentes tipos de patrones:

- espaciales (CNN, U-Net),
- secuenciales (LSTM, Transformers)
- y generativos (GANs).




Geometric Architectures of Deep Learning Models





Arquitecturas Avanzadas:

Redes Adversariales Generativas



Redes Adversariales


Aprendizaje de distribuciones complejas de datos físicos.



Introducción a PINNs


Redes Neuronales Informadas por Física para optimizar transporte de hidrógeno

Las Redes Neuronales Informadas por Física (PINNs) integran principios físicos en el entrenamiento de modelos, resolviendo ecuaciones diferenciales como las de difusión.






Arquitectura de Redes Neuronales Informadas por Física



Estructura de la red

A diferencia de CNN, U-Net o GAN, las PINNs incorporan las ecuaciones físicas en el entrenamiento, permitiendo resolver directamente sistemas gobernados por ecuaciones diferenciales y obtener soluciones físicamente consistentes.





Beneficios PINN

Ecuaciones Diferenciales

Capacidad de resolver ecuaciones complejas sin discretización.



Datos Experimentales

Menor necesidad de datos físicos para entrenamiento.



Generalización

Capacidad de aplicar conocimientos a diversos problemas.






Introducción al hidrógeno

La importancia del hidrógeno en la transición energética y tecnologías limpias

El hidrógeno es una **fuentes de energía limpia** y sostenible, esencial en la reducción de emisiones de CO₂. Su capacidad para almacenar y transportar energía lo convierte en un elemento clave para las tecnologías limpias y la transición energética, permitiendo un futuro más sostenible y menos dependiente de combustibles fósiles.






Retos en el Transporte de Hidrógeno



Fragilización y Permeabilidad

Los desafíos incluyen alta **permeabilidad** y **riesgos de fugas**.




$$2 \times 10^{-8} \text{ cm} = 0.00000002 \text{ cm}$$

El tamaño molecular extremadamente pequeño del hidrógeno permite su **rápida difusión** a través de diversos materiales, lo que plantea desafíos significativos para su almacenamiento y transporte seguros.



Definición del problema físico

$$\frac{\partial C}{\partial t} = D \left(\frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial C}{\partial r} \right) \right)$$




Difusión de hidrógeno

Es un proceso físico fundamental mediante el cual las moléculas o partículas se mueven desde una región de mayor concentración hacia otra de menor concentración

“El hidrógeno se difunde extremadamente




Definición del problema físico



Permeabilidad de hidrógeno

Es un proceso físico fundamental mediante el cual las moléculas o partículas se mueven desde una región de mayor concentración hacia otra de menor concentración



Modelo físico del transporte de hidrógeno

Ecuación de difusión

$$\frac{\partial u}{\partial t} = D \left[\frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial u}{\partial r} \right) + \frac{1}{r^2} \frac{\partial^2 u}{\partial \phi^2} + \frac{\partial^2 u}{\partial z^2} \right]$$

Componentes clave:

t: Tiempo

r: Radio

ϕ : Ángulo azimutal

z: Altura

D: Coeficiente de difusión o difusividad térmica

Ecuación de Permeabilidad del

H₂

$$J = -P \frac{\partial C}{\partial r}$$



Métodos de simulación

Diferencias finitas (FDM)

Aproximan derivadas en dominios discretizados.




Elementos finitos (FEM)

Discretizan el dominio para resolver problemas complejos.



Método Monte Carlo

Usa simulaciones aleatorias para aproximar soluciones.






85% más costo computacional

Los métodos FEM y Monte Carlo requieren discretizaciones finas en geometrías cilíndricas, lo que incrementa significativamente el tiempo de cómputo y limita su eficiencia para simular la difusión y permeabilidad del hidrógeno.

PINNs eliminan la necesidad de
mallado




Enfoque de PINNs en el transporte de hidrógeno



Solución eficiente

PINNs permiten simular el transporte de hidrógeno efectivamente.



Que hace un entrenamiento con DF?

Estructura del código

Malla radial + esquema implícito + resolución matricial
por caso paramétrico.

Con Diferencias finitas
resolvemos:

$$C(r,t;D,C_{in})$$

pero cada par (D, C_{in}) requiere:

for each D:

for each C_{in} :


solve DF

Costo total:

100 valores de D

100 valores de C_{in}

→ 10.000 simulaciones DF.





PINN parametrica

Estructura del código

El código implementa la red neuronal para simulación.

La red aprende:

$$N(r,t,\log D,C_{in}) \approx C(r,t;D,C_{in})$$

Es decir:

- La red aprende el operador solución completo.
- No aprende un caso.
- Aprende la familia de soluciones.


Durante entrenamiento:

- Se muestrean muchos D dentro de un rango
- Se muestrean muchos C_{in} dentro de un rango
- La pérdida fuerza que el PDE se cumpla para todos

Después del entrenamiento:


Para un nuevo D y C_{in} :

$$C_{pred} = \text{model}(r,t,D_{new},C_{in_new})$$





Resultados PINN parametrica vs DF



Eficiencia y Precisión

PINNs muestran **mejor rendimiento** comparado con métodos tradicionales.



Métricas de Evaluación

case	train_total_s_one_time	D	Cin	df_time_s	pinn_eval_s	rmse_vs_df	relL2_vs_df	Linf_vs_df
test_01	252,931,516	0.00	17,876	145,985	121,673	20,029	199,653	141,472
test_02	252,931,516	0.00	29,809	151,586	123,069	32,689	223,281	278,684
test_03	252,931,516	0.00	2,404	151,943	138,255	33,235	24,611	197,128
test_04	252,931,516	0.00	35,817	151,969	123,942	64,589	319,336	343,141
test_05	252,931,516	0.00	22,645	152,079	124,122	27,836	223,615	18,182
test_06	252,931,516	0.00	37,807	152,087	135,602	59,902	299,633	347,468
test_07	252,931,516	0.00	7,686	151,179	124,413	21,537	514,133	69,473
test_08	252,931,516	0.00	3,821	152,506	125,069	65,091	315,879	345,997
test_09	252,931,516	0.00	12,895	151,394	123,394	25,811	425,527	112,513
test_10	252,931,516	0.00	28,932	153,017	122,519	44,507	277,741	243,517




Métricas de Evaluación

N_cases	DF_total_time_ s	PINN_total_time_ _s				
10	151	25.419				
100	1.514	26.555				
1000	15.137	37.914				
10000	151.375	151.499				



PINN vs DF

Criterio	DF + Monte Carlo	PINN Paramétrica (r,t,D,Cin)
Modelo físico	Exactamente el PDE discretizado	Aprende solución del PDE (aproximación continua)
Costo por caso individual	Muy bajo (milisegundos–segundos)	Inferencia muy rápida
Costo si 1 simulacion	Mejor opción	Sobre-dimensionado
Costo si hay 10.000 simulaciones	Crece linealmente con N casos	1 entrenamiento + N inferencias
Multiparámetro (D, Cin, BC, etc.)	Requiere correr DF para cada combinación	Aprende mapa solución en espacio de parámetros
Tiempo total en UQ masivo	Alto (N × solve time)	Bajo (1 train + N eval)
Memoria requerida	Muy baja	Moderada–alta en entrenamiento
Escalabilidad en dimensión del parámetro	Mala (explota combinatoriamente)	Buena si la red está bien entrenada
Continuidad suave en parámetros	No garantizada (grid discreto)	Naturalmente continua
Robustez numérica	Muy alta (si esquema es estable)	Depende del entrenamiento
Interpretabilidad	Totalmente física	Aproximación entrenada





Conclusiones

El modelo DF cilíndrico es el referente físico-numérico

- Resuelve directamente la PDE de difusión radial.
- Garantiza cumplimiento estricto de condiciones de frontera.
- Es altamente preciso y estable.
- Ideal para análisis determinísticos de pocos casos.

La PINN paramétrica aprende la familia completa de soluciones

La red neuronal no aprende un caso particular, sino:

$$C=f(r,t,D,C_{in})$$

Esto significa que:

- Puede generalizar a combinaciones no vistas.
- Permite evaluación directa sin reentrenar.
- Funciona como un operador continuo en el espacio paramétrico.





Conclusiones

Escalabilidad computacional

- DF escala linealmente con el número de casos.
- PINN tiene costo fijo de entrenamiento + costo bajo por inferencia.
- La ventaja aparece en estudios masivos (Monte Carlo / UQ).

DF resuelve un problema.

La PINN paramétrica aprende el espacio de soluciones.

Ventaja estratégica

La PINN es especialmente útil cuando:

- Se requieren miles de evaluaciones.
- Se estudian incertidumbres paramétricas.





Contacto

Redes Neuronales Informadas por Física (PINNs)

URL

www.dci-energy.com

CORREO

j.vegad@uniandes.edu.co
juan.vega@dci-energy.com

TELÉFONO

+57 -3508097784

