



El Fin del Monopolio Convolutivo

Más allá de las CNNs: Vision Transformers, Redes Adversarias y el futuro del análisis visual.




LA DIVERGENCIA ARQUITECTÓNICA

NLP



ESCALABILIDAD INFINITA SIN SATURACIÓN DE RENDIMIENTO.

COMPUTER VISION



ESTANCAMIENTO EN HÍBRIDOS COMPLEJOS (CNN + ATENCIÓN LOCAL).

LA VISIÓN POR COMPUTADORA ASUMÍA QUE LAS CNNs ERAN INDISPENSABLES. EL ARTÍCULO VISION TRANSFORMER (ViT) DEMUESTRA QUE ESTA DEPENDENCIA ES UNA ILUSIÓN.

El origen del paradigma: Dominio absoluto en NLP y escalabilidad ilimitada

El Estándar De-Facto


El ecosistema de NLP fue conquistado definitivamente por la arquitectura de auto-atención de Vaswani et al. (2017).

El Método

Entrenamiento masivo auto-supervisado en corpus de texto gigantes, seguido de refinamiento (fine-tuning) para tareas específicas.

La Ventaja Clave

A diferencia de las arquitecturas previas, el rendimiento de los Transformers crece linealmente con los datos. Modelos de más de 100 mil millones de parámetros se entrenan sin saturar el rendimiento.




El núcleo de procesamiento: Auto-atención multi-cabezal (MSA)

Metáfora del Motor de Búsqueda



Comparativa de Arquitecturas: Local vs. Global

Redes Convolucionales (Sesgo Local)



Visión de túnel. Procesa píxeles adyacentes paso a paso mediante ventanas limitadas.

Auto-Atención (Recepción Global)



Integración instantánea. Calcula la similitud entre todos los pares de elementos de la secuencia simultáneamente desde la primera capa.

Multi-Cabezal: Múltiples proyecciones Q-K-V se ejecutan en paralelo para capturar diversas relaciones semánticas.

Arquitectura del bloque codificador: Una cadena de montaje matemática

Topología Constante


Los vectores latentes mantienen un tamaño fijo (D) a lo largo de todas las capas, garantizando que los bloques sean módulos matemáticamente idénticos y apilables.

Anatomía Interna


- **LayerNorm (LN):** Aplicada antes de cada bloque para estabilizar gradientes en arquitecturas profundas.
- **Bloque MSA:** El motor central de atención y enrutamiento de información global.
- **Bloque MLP:** Procesamiento local no lineal (GELU) aplicado individualmente a cada token.

El Carril de Desvío (Residuales)

Las conexiones residuales (flechas de bypass) suman la señal original intacta tras cada sub-bloque. Esto previene la degradación de la información a través de cientos de capas.



La adaptación a la visión (ViT): Una imagen equivale a 16x16 palabras



Parches como Palabras

El veloz zorro marrón




Secuencia de Tokens 1D



Para el codificador Transformer, no hay diferencia entre una oración y una imagen. Ambos son simplemente secuencias de tokens discretos.


ANATOMÍA DEL VISION TRANSFORMER (ViT)

1. Imagen 2D dividida físicamente en bloques (Parches).




2. Aplanamiento en vectores 1D + Proyección Lineal


$$x \in \mathbb{R}^{H \times W \times C} \rightarrow x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$$




3. Inserción del token [class] y suma de Incrustaciones Posicionales.



4. Paso a través de capas alternas de Atención (MSA) y bloques MLP.



El Intercambio: Datos vs. Sesgo Inductivo




Diagnostic

CNNs: Poseen reglas de diseño horneadas (equivarianza de traslación, localidad). Ganan en escasez de datos.

ViT: Carece de sesgos inductivos. Aprende todas las relaciones espaciales desde cero. El entrenamiento a hiperescala (JFT-300M) triunfa sobre el sesgo inductivo.


La Visión Global Instantánea

CNN: Comprensión local construida progresivamente.




Área de atención localizada y en expansión.

ViT: Atención global desde la capa cero.



ViT no necesita múltiples capas para ver el panorama completo.
Integra información semántica de toda la imagen de forma inmediata.

Reconstruyendo el Espacio en 1D



El problema

Al aplanar los parches, se pierde la geometría 2D.


La solución

Se suman vectores de posición aprendibles a cada parche.

El resultado


ViT aprende automáticamente la topología original de la imagen. La similitud del coseno revela que los parches cercanos en el espacio 2D desarrollan representaciones posicionales.

El Vacío de las Etiquetas y el Pivote Adversario



ViT es un gigante hambriento de datos supervisados. Pero el mundo real está lleno de datos sin etiquetar. Para dominar el análisis de imágenes con datos limitados, pasamos de un enfoque discriminativo puro a un ecosistema generativo adversario: Las GANs.

GANs: Más Allá de la Generación Sintética




Mientras el mundo se enfoca en las imágenes falsas que crea el Generador, el verdadero valor analítico reside en el Discriminador. Al jugar a este juego Minimax, el Discriminador se ve forzado a aprender las características más intrínsecas y semánticas de la imagen.

Mapeo del Espacio Latente para Clasificación

Reutilización de Pesos

Las capas convolucionales del Discriminador pre-entrenado se congelan y se usan como extractores de características robustas.

Capas del Discriminador
(Extractores de Características)



Structure layers

Analytical sensor

El Espacio Latente

Magia Semi-Supervisada

Solo requiere una fracción de las etiquetas comparado con arquitecturas convencionales.

Búsqueda de Anomalías

Lo que el Discriminador clasifica firmemente como falso a menudo señala anomalías valiosas en datos del mundo real.



Clasificación Clase 1: Normal



Clasificación Clase 2: Anomalia




Clasificación Clase 3: Variación Desconocida

Síntesis Analítica: ViT vs. GANs

Dimensión	<u>Vision Transformers (ViT)</u>	<u>Generative Adversarial Networks (GANs)</u>
Enfoque Principal	Discriminativo Directo	Generativo Adversario
Mecanismo de Aprendizaje	Atención Global sobre Tokens	Juego Minimax y Divergencia
Tratamiento de la Imagen	Secuencia de parches independientes	Distribución de píxeles continuos
Dependencia de Datos	Extrema - requiere millones de datos etiquetados	Moderada - aprovecha vastos océanos de datos no etiquetados
Aplicación Estrella	Precisión SOTA en reconocimiento visual a gran escala	Clasificación semi-supervisada y detección de anomalías especializadas

El Futuro Dual de la Visión Computacional



1

Escala Pura

ViT demuestra que si posees los datos y el cómputo, la atención global erradica la necesidad de reglas convolucionales predefinidas.

2

Eficiencia Latente

Las GANs demuestran que la competencia adversaria puede desentrañar la semántica visual profunda sin intervención humana.

3

El Criterio Arquitectónico

La elección ya no es qué red es mejor, sino cuál es la estructura subyacente de nuestros datos.