

RETO 1: The Movies Dataset

Objetivo

En este reto se pretende poner en práctica los conceptos aprendidos en clase acerca de las estructuras de datos lineales del módulo No. 1. Como lo son: (1) las listas, pilas y colas y (2) los algoritmos de búsqueda

Específicamente se pretende:

1. **Aprender** a cargar y procesar en memoria datos en formato CSV.
2. **Practicar** los conceptos sobre estructuras lineales (listas, pilas y colas).
3. **Practicar** los algoritmos de búsquedas lineales.
4. **Utilizar** adecuadamente el administrador de versiones GIT y GitHub.
5. **Fortalecer** el trabajo en equipo.

Fecha Límite de Entrega

El reto podrá entregarse hasta el martes **17** de **septiembre**, 11:59 p.m.
Ver las condiciones de entrega en la sección Entrega.

Contexto

MovieLens es un proyecto creado por el Grupo de Investigación de Sistemas de Recomendación de la universidad de Minnesota. MovieLens es una plataforma que proporciona información como reparto, equipo de producción, presupuesto, ingresos, posters, fechas de publicación idiomas y puntuaciones de más de 45.000 películas con fecha de publicación de antes de Julio de 2017.

MovieLens los ha seleccionado para llevar a cabo un análisis del histórico de películas almacenadas en la plataforma a lo largo de los años. El dataset completo incluirá información de películas de 1960 (Fecha menor) hasta el 2020 recopilando un total de 45.000 películas de diferentes géneros y países de origen. Los datos resultantes de la recopilación también incluyen rendimientos financieros de las películas incluyendo el presupuesto de producción y recolección de taquilla junto con otros datos fundamentales para perfilar y analizar desempeños del conjunto de datos.

Carga de Datos

Los datos del reto fueron tomados del proyecto **Kaggle** publicado por *Rounak Banik* titulado “**The MoviesDataset**” que recopila la información 45.000 películas publicadas antes de Julio del 2017¹ Los datos útiles para el proyecto están preparados y disponibles para los estudiantes en el aula **unificada** en Bloque Neón (BrightSpace).

En particular, la información está conformada por cuatro archivos CSV en formato UTF-8 que se describen a continuación:

- a) El archivo **movies-*.csv**, contiene la información relevante a las películas publicadas. Como se ve en **Tabla 1**, este archivo incluye identificación de la película, título original, presupuesto de producción, categoría infantil, lenguaje original y otros datos relevantes sobre la producción de las películas. El * en el nombre anteriormente mencionado hace referencia a los diferentes tamaños de datos de información presentados en los datos.

NOMBRE DE LA COLUMNA	DESCRIPCIÓN
<i>id</i>	Identificación de IMDB de la película. La usaremos como identificador de la película
<i>title</i>	Título de la película
<i>original_language</i>	Idioma original de grabación de la película.
<i>release_date</i>	Fecha de publicación de la película. Se tiene en cuenta solo si llegó a status “Released”
<i>revenue</i>	Ingresos netos de la película al momento de publicación.
<i>runtime</i>	Duración en minutos de la película.
<i>status</i>	Estado de la película. Por ejemplo: Released, Rumored, In Production u otros.
<i>vote_average</i>	Puntaje promedio de las votaciones de los críticos. El rango es entre 0 y 10.
<i>vote_count</i>	Número total de votaciones de críticos.
<i>budget</i>	Presupuesto asignado a la producción de la película
<i>genres</i>	Lista de géneros en los que se clasifica la película. Esta columna contiene los datos de JSONs en manera de String. Los géneros tienen la estructura de: id y name
<i>production_companies</i>	Lista de empresas productoras involucradas en la creación de la película. Esta columna contiene los datos de JSONs en manera de String. Las compañías tienen la estructura de: id y name

Tabla 1. Nombres y descripción de las propiedades de datos de las ofertas de trabajo.

Para manejar las columnas de tipo JSON (genre y production_companies) almacenadas como String, utilice de la librería nativa de Python *json* la función *loads(string)* para convertir los textos de las columnas a un objeto manejable por Python. Una vez los textos son convertidos a JSON estos se pueden utilizar como diccionarios de Python que, en este caso, una vez es usada la función *load* retorna una lista de objetos a los cuales se les puede acceder como si se accediera a un diccionario de Python. El siguiente fragmento de código es un ejemplo de

¹ The Movie Dataset, Kaggle, URL https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset?resource=download&select=movies_metadata.csv

como cargar la columna *genre* de String a JSON y posterior mente recorrer la lista para guardarla en las estructuras de datos necesaria.

```
import json

movies = csv.DictReader(open(data_dir, encoding='utf-8'))

for movie in movies:
    genres_list = json.loads(movie["genres"])
    for genre in genres_list:
        genre = create_genre(genre["id"], genre["name"])
```

Para evitar problemas de buffer en la lectura de los archivos se recomienda aumentar el tamaño de los campos de lectura de la librería **Python CSV** al máximo posible para el sistema con el siguiente comando en la librería CSV en el **logic.py** del Reto.

```
import csv

...

csv.field_size_limit(2147483647)
```

En algunos casos experimentales puede que Python y el IDE declaren que se alcanzó el límite de recursión con un mensaje “**RecursionError: maximum recursion depth exceeded in comparison**”, en este caso se recomienda actualizar en el **view.py** este límite con las siguientes líneas de código:

```
import sys

...

default_limit = 1000

sys.setrecursionlimit(default_limit*10)
```

Trabajo Propuesto

Parte 1: Configuración Repositorio

Complete los siguientes pasos para configurar su repositorio de trabajo:

- p.1.** Cree en GitHub un repositorio basado en la plantilla propuesta para el reto, el cual se encuentra en el URL: <https://github.com/ISIS1225DEVs/ISIS1225-Reto-Template>
- p.2.** Renombre el repositorio de su reto con el formato **Reto1-G<<Número del grupo>>** ej.: **Reto1-G01** para el grupo 1 de la sección.
- p.3.** Edite el **README** del repositorio e incluya los nombres completos, correo Uniandes y códigos de los miembros del equipo de trabajo.
- p.4.** Realice el procedimiento según lo aprendido en clase para clonar el repositorio en su máquina local y sincronizarlo con su repositorio en GitHub.

- p.5.** Descargue los datos desde la sección unificada del curso y cópielos en la carpeta **data** del repositorio local.

Parte 2: Carga de Datos

En la sección de **Reto 1**, de la sección **unificada** en Bloque Neón, encontrarán los datos oficiales del reto. El ZIP contiene varios archivos con los sufijos **-small**, **-medium** y **-large**. Estos son archivos con diferente número de registros. (ej.: el archivo **movies-small.csv** contiene una tercera parte de los datos con 14.860 registros y el archivo **movies-large.csv** contiene la totalidad de los datos con 45.031 registros). Esto facilita la implementación y pruebas en computadores con memoria RAM y procesadores reducidos.

Para responder los requerimientos deberán cargar la información de los archivos entregados; recuerde que solo se permite leer una vez la información de cada archivo y que las pruebas finales sobre sus algoritmos serán sobre los archivos ***-large.csv**.

Al completar la carga de datos de las ofertas de trabajo (**movies-*.csv**) se debe reportar los siguiente:

- El total de películas cargadas.
- La información de las cinco primeras y cinco últimas películas cargadas. Cada elemento debe contener los siguientes detalles:
 - Fecha de publicación.
 - Título original de la película.
 - Idioma original en que fue grabada la película.
 - Duración en minutos de la película.
 - Presupuesto de producción de la película.
 - Ingresos de taquilla netos de la película.
 - Ganancias de la película.

Recomendaciones:

- En caso de que una película no contenga ningún género, puede crear un género que identifique a las películas que no tengan ninguno asignado.
- En caso de que una película no contenga ninguna compañía productora, cree una compañía llamada "Indefinida" asignada a las películas cuya compañía productora no se encuentra identificada.
- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como "Indefinido" o "Undefined"
- Se recomienda utilizar las librerías nativas de Python de datetime² para manejar el procesamiento y comparaciones de los datos temporales dentro de los archivos.
- Se recomienda utilizar librerías por extensión de Python como tabulate³ para imprimir adecuadamente los resultados como se muestran en los ejemplos.
- En caso de que no exista algún valor dentro de los campos solicitados, completarlos con el valor "Desconocido" o "Unknown".


² Librería Python datetime, Python URL: <https://docs.python.org/3/library/datetime.html>

³ librería Python tabulate, PyPi URL: <https://pypi.org/project/tabulate/>

Parte 3: Desarrollo de los Requerimientos

Para este reto se ha identificado **ocho (8) requerimientos: siete (7) obligatorios y un (1) bono**. Divididos según dificultad en básico, intermedio y avanzado. Adicionalmente, es importante resaltar que **tres (3)** de estos requerimientos se deben desarrollar de forma **individual** y los **cinco (5)** restantes son **grupales**.

El resumen de los requerimientos se muestra en la siguiente tabla y se explican detalladamente en la siguiente sección.



Comentario: Incluir la imagen con los grupos de requerimientos básicos 1 y 2, intermedios 3, 4 y 5, avanzados 6 y 7 y Bono 8.

NOTA: Si el equipo este conformado solamente por **dos (2)** integrantes deberán resolver solamente **cinco (5) requerimientos obligatorios: uno (1)** de los requerimientos **básicos**, **dos (2)** de los requerimientos **intermedios**, y los **dos (2)** primeros requerimientos **avanzados**. Opcionalmente, el último requerimiento **avanzado (Bono)**.

Requerimiento No. 1 (Grupal): Listar la última película publicada según su duración en minutos

Como experto en películas **quiero** listar la última película publicada (v.gr. la más reciente) ofrecida que supere un tiempo mínimo de duración en minutos.

Los **parámetros de entrada** de este requerimiento son:

- Tiempo mínimo de duración en minutos de la película (ej.: 60, 80 o 100).

La **respuesta esperada** debe contener:

- El número total de películas que cumplieron con el tiempo mínimo en minutos
- Para la película resultante se debe presentar la siguiente información:
 - Tiempo de duración en minutos de la película
 - Fecha de publicación de la película
 - Título original de la película
 - Presupuesto destinado a la realización de la película
 - Dinero recaudado neto por la película
 - Ganancia de final de la película
 - Puntaje de calificación de la película
 - Idioma original de publicación

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como **“Indefinido”** o **“Undefined”**.

Requerimiento No. 2 (Grupal): Listar la última película publicada dado su idioma original

Como experto de películas **quiero** conocer la última película publicada (v.gr. la más reciente) que se halla publicado en un idioma original específico.

Los **parámetros de entrada** de este requerimiento son:

- Idioma original de publicación (ej.: en, fr, zh).

La **respuesta esperada** debe contener:

- El número total de películas publicadas en el idioma original de consulta.
- Para la película de la consulta se debe presentar la siguiente información:
 - Fecha de publicación de la película
 - Título original de la película
 - Presupuesto destinado a la realización de la película
 - Dinero recaudado por la película
 - Ganancia de final de la película
 - Tiempo de duración en minutos de la película
 - Puntaje de calificación de la película

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como “**Indefinido**” o “**Undefined**”.

Requerimiento No. 3 (Individual): Listar las películas en un idioma en específico para un periodo de tiempo dado

Como analista de datos **quiero** consultar las películas en un idioma original entre un rango de fechas de publicación dado.

Los **parámetros de entrada** de este requerimiento son:

- Idioma original de publicación (ej.: en, fr, zh).
- La fecha inicial del periodo a consultar (con formato "%Y-%m-%d").
- La fecha final del periodo a consultar (con formato "%Y-%m-%d").

La **respuesta esperada** debe contener:

- Número total de películas que cumplen el criterio.
- Tiempo promedio de duración de las películas que cumplen el criterio de búsqueda.
- El listado de películas resultante donde para cada una contendrá la siguiente información:
 - Fecha de publicación de la película (con formato "%Y-%m-%d")
 - Título original de la película
 - Presupuesto destinado a la realización de la película
 - Dinero recaudado por la película
 - Ganancia de final de la película
 - Tiempo de duración en minutos de la película
 - Puntaje de calificación de la película
 - Estado de la película

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como **"Indefinido"** o **"Undefined"**.
- Si la lista de películas que cumplen el criterio supera más de 20 elementos, presente solamente las primeras 5 y las últimas 5 películas que se encuentran en la lista de respuesta.

Requerimiento No. 4 (Individual): Listar las películas con un estado de publicación entre un periodo de tiempo dado

Como analista de datos **deseo** consultar las películas a partir de un estado de producción dado un rango de fechas.

Los **parámetros de entrada** de este requerimiento son:

- Estado de producción de la película (ej.: "Released", "Rumored", etc).
- La fecha inicial del periodo a consultar (con formato "%Y-%m-%d").
- La fecha final del periodo a consultar (con formato "%Y-%m-%d").

La **respuesta esperada** debe contener:

- Número total de películas que cumplen el criterio.
- Tiempo promedio de duración de las películas que cumplen el criterio de búsqueda.
- El listado de películas resultante donde para cada una contendrá la siguiente información:
 - Fecha de publicación de la película
 - Título original de la película
 - Presupuesto destinado a la realización de la película
 - Dinero recaudado por la película
 - Ganancia de final de la película
 - Tiempo de duración en minutos de la película
 - Puntaje de calificación de la película
 - Idioma original de publicación

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como "**Indefinido**" o "**Undefined**".
- Si la lista de películas que cumplen el criterio supera más de 20 elementos, presente solamente las primeras 5 y las últimas 5 películas que se encuentran en la lista de respuesta.

Requerimiento No. 5 (Individual): Consultar las películas que tengan una duración entre un rango de tiempo dado

Como analista de datos **quiero** consultar las películas que tengan una duración en minutos entre un rango de tiempo en minutos dado un rango de fechas.

Los **parámetros de entrada** de este requerimiento son:

- Límite inferior de tiempo de duración (ej.: 50, 60 o 90).
- Límite superior de tiempo de duración (ej.: 100, 120 o 140)
- La fecha inicial del periodo a consultar (con formato "%Y-%m-%d").
- La fecha final del periodo a consultar (con formato "%Y-%m-%d").

La **respuesta esperada** debe contener:

- Número total de películas que cumplen el criterio de búsqueda.
- Tiempo promedio de duración de las películas que cumplen el criterio de búsqueda.
- El listado de películas donde para cada una contendrá la siguiente información:
 - Fecha de publicación de la película
 - Título original de la película
 - Presupuesto destinado a la realización de la película
 - Dinero recaudado por la película
 - Ganancia de final de la película
 - Tiempo de duración en minutos de la película
 - Puntaje de calificación de la película
 - Idioma original de publicación

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como **"Indefinido"** o **"Undefined"**.
- Si la lista de películas que cumplen el criterio supera más de 20 elementos, presente solamente las primeras 5 y las últimas 5 películas que se encuentran en la lista de respuesta.

Requerimiento No. 6 (Grupal): Analizar las películas publicadas en un idioma de origen durante un periodo de años

Como analista de datos **deseo** conocer la estadística de las películas publicadas por año entre un rango de años dado y en un idioma dado. Una película se considera publicada si su status es *Released*.

Los **parámetros de entrada** de este requerimiento son:

- Idioma original de publicación (ej.: en, fr, zh).
- Año inicial del periodo a consultar (con formato "%Y" ej.: "1998").
- Año final del periodo a consultar (con formato "%Y" ej.: "2024").

La **respuesta esperada** debe contener:

- Para cada año en el periodo de consulta informar:
 - El año del listado
 - El total de películas publicadas en el idioma de consulta en ese año.
 - El promedio de la votación promedio de estas películas publicadas en ese año.
 - El tiempo promedio de duración de estas películas publicadas en ese año.
 - Las ganancias acumuladas por todas estas películas en ese año.
 - Nombre y puntuación de la película con mejor votación promedio publicada en el año.
 - Nombre y puntuación de la película con peor votación promedio publicada en el año.

Recomendaciones:

- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como **"Indefinido"** o **"Undefined"**.

Requerimiento No. 7 (Grupal): Analizar las películas publicadas por una compañía productora en un periodo de años

Como analista de datos, **deseo** conocer la estadística de las películas publicadas por año entre un rango de años dado y de una compañía productora dada. Una película se considera publicada si su status es *Released*.

Los **parámetros de entrada** de este requerimiento son:

- Nombre de compañía productora. (ej. "Nilsen Premiere")
- La fecha inicial del periodo a consultar (con formato "%Y").
- La fecha final del periodo a consultar (con formato "%Y").

La **respuesta esperada** debe contener:

- Para cada año en el periodo de consulta informar:
 - El año del listado
 - El total de películas publicadas por la compañía en ese año
 - El promedio de la votación promedio de estas películas publicadas en ese año
 - El tiempo promedio de duración de estas películas publicadas en ese año
 - Las ganancias acumuladas por todas estas películas en ese año
 - Nombre y puntuación de la película con mejor votación promedio publicada en el año.
 - Nombre y puntuación de la película con peor votación promedio publicada en el año.

Recomendaciones:

- En caso de que una película tenga más de una compañía productora, tenga en cuenta todas las compañías productoras y cuente cada película para cada compañía por aparte.
- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como **"Indefinido"** o **"Undefined"**.

Requerimiento No. 8 (Bono): Consultar las películas de un género que hayan estado disponibles a partir de su publicación en un año específico.

Como analista de datos, **deseo** conocer la estadística de las películas publicadas en un año y de un género dados. Una película se considera publicada si su status es *Released*.

Los **parámetros de entrada** de este requerimiento son:

- Año de consulta
- Género de la película

La **respuesta esperada** debe contener:

- Para el año y género de consulta informar:
 - El total de películas publicadas resultado de la consulta
 - El promedio de la votación promedio de estas películas de la consulta.
 - El tiempo promedio de duración de estas películas de la consulta
 - Las ganancias acumuladas por estas películas de la consulta
 - Nombre y puntuación de la película con mejor votación promedio publicada en el año.
 - Nombre y puntuación de la película con peor votación promedio publicada en el año.

Recomendaciones:

- En caso de que una película tenga más de un género, tenga en cuenta todos los géneros en los que fue clasificada.
- Las ganancias de una película se pueden calcular teniendo en cuenta el presupuesto de la película y los ingresos netos en la taquilla de la película. En caso de no tener presupuesto o ingresos netos se define como “**Indefinido**” o “**Undefined**”.

Parte 4: Análisis de resultados

Dentro del proyecto debe incluir, en la carpeta **Docs**, un documento en formato **PDF** donde se evidencie el análisis de complejidad y las pruebas de tiempos de ejecución para cada requerimiento. Se sugiere que el documento tenga la siguiente distribución del contenido:

- Nombres, código y correo Uniandes de los integrantes del grupo.
- Para los requerimientos individuales se debe indicar que estudiante del equipo lo realizó.
- Análisis de complejidad de los requerimientos en Notación O.
- Pruebas de tiempos de ejecución para cada uno de los requerimientos. En estas pruebas se deben incluir:
 - Las tablas de tiempos de ejecución registrados.
 - Las gráficas comparativas de los experimentos.
 - Un análisis de resultados comparándolo los resultados obtenidos con el análisis de complejidad realizado.

Recomendaciones:

- Tomen como guía las herramientas, metodología y análisis realizados en los laboratorios; en especial el laboratorio 4.
- Ejecute las pruebas de los requerimientos siempre con los mismos parámetros de entrada y con los archivos más grandes que pueda procesar su computador.
- Ejecute las pruebas de los requerimientos con la configuración optima del catálogo (ej. Utilizando linked list o array list)

Entrega

Para realizar la entrega del reto deben:

- 1) Agregar los usuarios de los monitores y profesores del curso a su organización de GitHub para hacer la entrega adecuada de la actividad,
- 2) Dar permisos adecuados repositorio a los monitores y al profesor, de lo contrario el reto **NO** podrá ser calificado,
- 3) Asegurarse que la visibilidad del repositorio entregado sea privada y que solo pueda accederse con los permisos configurados para los integrantes del grupo,
- 4) Enviar el enlace de GitHub en la actividad correspondiente dentro de Bloque Neón Uniandes (BrightSpace) de su sección.
- 5) Incluir en el repositorio GIT todo el material, código y documentos solicitados durante la actividad.

IMPORTANTE: Recuerde que solo se calificará el material hasta el último **COMMIT** realizado previo a la Fecha/Hora Límite de Entrega indicada al inicio de este enunciado.