

Taller 07

ANOVA & Kruskal-Wallis

AUTOR/A

Integrante

FECHA DE PUBLICACIÓN

25 de marzo de 2025

En **todos** los puntos del taller **debe** realizar todos los siguientes pasos:

- i. Explorar visualmente la distribución del conjunto de datos asociado a la investigación.
- ii. Plantear la hipótesis nula y la alternativa teniendo en cuenta la pregunta de investigación mencionada.
- iii. Definir el nivel de significancia (α) y justificar su selección.
- iv. Evaluar la normalidad de las variables que lo requieran.
- iv. Escoger la prueba estadística adecuada (validar que se cumplan todos los supuestos para su selección).

1. Ardillas y Pinos [2.5]

Los datos `pines-squirrels.tsv` representan el tamaño de cono (masa) de una especie de pino en 16 sitios de estudio en tres tipos de ambientes en el occidente de USA (Edelaar & Benkman, 2006). Los tres ambientes hacían referencia a:

- Ambiente I: Isla con ardillas
- Ambiente II: Isla sin ardillas
- Ambiente III: Continente con ardillas.

```
library(readr)
library(ggplot2)

ard <- read.csv("pines-squirrels.tsv", sep="")
ard
```

	environment	coneMass
1	I	9.6
2	I	9.4
3	I	8.9
4	I	8.8

5	I	8.5
6	I	8.2
7	I	9.2
8	I	9.1
9	I	9.9
10	I	9.3
11	I	9.1
12	I	9.3
13	I	9.2
14	I	9.1
15	I	9.3
16	I	9.1
17	I	8.9
18	I	9.2
19	I	9.1
20	I	9.3
21	I	9.1
22	I	9.2
23	I	8.6
24	I	9.4
25	I	9.1
26	I	9.3
27	I	9.3
28	I	9.1
29	I	8.9
30	I	9.2
31	I	9.1
32	I	9.3
33	I	9.7
34	I	9.3
35	I	9.2
36	I	9.1
37	II	6.2
38	II	6.3
39	II	6.4
40	II	6.1
41	II	6.3

42	II	5.9
43	II	6.6
44	II	6.7
45	II	6.3
46	II	6.9
47	II	6.6
48	II	6.5
49	II	5.7
50	II	6.9
51	II	6.6
52	II	6.5
53	II	6.7
54	II	6.7
55	II	6.9
56	II	6.6
57	II	6.5
58	II	6.9
59	II	6.9
60	II	6.9
61	II	6.8
62	II	6.1
63	II	6.7
64	II	6.7
65	II	6.9
66	II	6.6
67	II	6.5
68	II	6.9
69	II	6.9
70	II	6.1
71	II	6.1
72	II	6.7
73	II	6.1
74	II	6.9
75	II	6.1
76	II	6.4
77	II	6.9
78	II	6.3


79	II	6.8
80	II	6.1
81	II	6.9
82	II	5.9
83	II	5.7
84	II	5.9
85	II	6.1
86	II	6.9
87	II	6.3
88	II	6.7
89	II	6.1
90	II	6.7
91	II	6.4
92	II	6.2
93	III	5.6
94	III	5.6
95	III	5.4
96	III	5.2
97	III	5.3
98	III	5.1
99	III	5.2
100	III	5.2
101	III	5.7
102	III	5.6
103	III	5.4
104	III	5.2
105	III	5.2
106	III	5.6
107	III	5.6
108	III	5.4
109	III	5.2
110	III	5.6
111	III	5.4
112	III	5.2
113	III	5.2
114	III	5.6
115	III	5.4

116	III	5.2
117	III	5.6
118	III	5.4
119	III	5.2
120	III	5.1
121	III	5.6
122	III	5.4
123	III	5.2
124	III	5.3
125	III	5.1
126	III	5.2
127	III	5.2
128	III	5.9
129	III	5.1
130	III	5.1
131	III	5.2
132	III	5.2
133	III	5.1
134	III	5.3
135	III	5.2
136	III	5.2

```
graf_and <- ggplot(data=ard,aes(x=coneMass,fill=environment))+  
  geom_histogram()+  
  facet_wrap(~environment)+  
  labs(x="Tamaño Cono", y="Frecuencia",fill="Ambiente", title="Histograma de Distribución de los datos")  
  theme(plot.title = element_text(hjust=0.5))
```


graf_and

`stat\_bin()` using `bins = 30`. Pick better value with `binwidth`.




```
boxplot_ard<- ggplot(ard, aes(x = environment, y = coneMass, fill = environment)) +
  geom_boxplot(color='black') +
  geom_jitter(width = 0.05, height = 0.05) +
  ylab("Tamaño Cono") +
  xlab("Ambiente") +
  theme_bw()+
  labs(title="BoxPlot Ambiente vs Tamaño Cono",fill="Ambiente")+ theme(plot.title = element_text(hjust=0.5))
```

boxplot_ard



```
densidad_ard <- ggplot(ard, aes(coneMass, fill=environment)) +
  facet_wrap(vars(environment)) +
  geom_density() +
  labs(x = 'Tamaño Cono', y = 'Frecuencia', fill="Ambiente", title = "Gráfica de Densidad") +
  theme_bw()+ theme(plot.title = element_text(hjust=0.5))
densidad_ard
```



Se plantea que: H_0 : El tamaño de cono en los 3 ambientes presentan igual promedio. H_a : Al menos uno o más de las medias del tamaño de cono es diferente a las medias de tamaño de cono de los otros ambientes

El nivel de significancia escogido es de 0.01, ya que este valor es más estricto en rechazar la hipótesis nula, esto con el propósito de tener la mayor seguridad posible de que si se rechaza la hipótesis nula es porque existe una probabilidad muy baja de cometer un error al hacerlo. Por ende, habría mayor certeza de la hipótesis alternativa es verdadera.

Primero se genera el test ANOVA y sus respectivos chequeos para conocer si cumple las asunciones del test.

```
library(tidyverse)
```

```

— Attaching core tidyverse packages — tidyverse 2.0.0 —
✓ dplyr      1.1.4    ✓ stringr  1.5.1
✓ forcats    1.0.0    ✓ tidbale   3.2.1
✓ lubridate  1.9.4    ✓ tidyr     1.3.1
✓ purrr      1.0.2

— Conflicts — tidyverse_conflicts() —
✖ dplyr::filter() masks stats::filter()
✖ dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors

```

```
library(performance)
```

Warning: package 'performance' was built under R version 4.4.3

```
anova_ard <- aov(data=ard, coneMass ~ environment)
summary(anova_ard)
```

```

              Df Sum Sq Mean Sq F value Pr(>F)
environment    2  298.98   149.49   1666 <2e-16 ***
Residuals   133   11.93    0.09
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
check_autocorrelation(anova_ard )
```

OK: Residuals appear to be independent and not autocorrelated (p = 0.120).

```
check_normality(anova_ard )
```

Warning: Non-normality of residuals detected (p = 0.042).


```
check_heteroskedasticity(anova_ard)
```

OK: Error variance appears to be homoscedastic (p = 0.173).

```
plot(check_homogeneity(anova_ard))
```

Homogeneity of Variance (Bartlett Test)


Groups should be evenly spread



```
plot(check_normality(anova_ard),type="density")
```

Normality of Residuals

Distribution should be close to the normal curve



```
plot(check_heteroskedasticity(anova_ard))
```

```
Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,  
: pseudoinverse used at 5.315
```

```
Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,  
: neighborhood radius 3.835
```

```
Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,  
: reciprocal condition number 5.5782e-16
```

```
Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,  
: There are other near singularities as well. 14.707
```

```
Warning in predLoess(object$y, object$x, newx = if (is.null(newdata)) object$x  
else if (is.data.frame(newdata))  
as.matrix(model.frame(delete.response(terms(object))), : pseudoinverse used at  
5.315
```


```
Warning in predLoess(object$y, object$x, newx = if (is.null(newdata)) object$x  
else if (is.data.frame(newdata))  
as.matrix(model.frame(delete.response(terms(object))), : neighborhood radius  
3.835
```

```
Warning in predLoess(object$y, object$x, newx = if (is.null(newdata)) object$x  
else if (is.data.frame(newdata))  
as.matrix(model.frame(delete.response(terms(object))), : reciprocal condition  
number 5.5782e-16
```

```
Warning in predLoess(object$y, object$x, newx = if (is.null(newdata)) object$x  
else if (is.data.frame(newdata))  
as.matrix(model.frame(delete.response(terms(object))), : There are other near  
singularities as well. 14.707
```

Homogeneity of Variance

Reference line should be flat and horizontal



De acuerdo con el nivel de significancia elegido los chequeos cumplen con los supuestos. Por tal motivo se elige el estadístico de prueba F.

i-V. Realice los pasos mencionados anteriormente. a. ¿Existen diferencias en el tamaño de cono entre los tres ambientes?

Según el valor-P obtenido en ANOVA se rechaza la hipótesis nula, es decir que, las medias del tamaño de los conos es diferente.

c. ¿Cuál es el ambiente con mayor tamaño de cono? Realice una prueba de comparaciones múltiples y conclusión biológica.

```
TukeyHSD(anova_ard)
```

```
Tukey multiple comparisons of means
 95% family-wise confidence level
```

```
Fit: aov(formula = coneMass ~ environment, data = ard)
```

```
$environment
      diff      lwr      upr p adj
II-I    -2.667857 -2.819511 -2.516203    0
III-I   -3.815909 -3.975450 -3.656368    0
III-II  -1.148052 -1.291068 -1.005036    0
```

Según la prueba de comparación múltiple de medias, el valor-P para todas las parejas creadas es de cero. Esto indica que para todas las pruebas de comparación generadas por la prueba Tukey se rechaza la hipótesis nula de que las medias son iguales, es decir que todos los promedios del tamaño de cono tienen valores diferentes para cada ambiente. No obstante, en el gráfico de BoxPlot se observa que el ambiente con mayor media en tamaño de cono es el ambiente I.

2. Supervivencia al Veneno [2.5 puntos]

Los datos `survival.tsv` corresponden a los resultados después del siguiente experimento: Se midió el tiempo de supervivencia de una serie de animales a los cuales se les asignó aleatoriamente un tipo de veneno (I, II y III) y un tipo de tratamiento (A, B, C, D).

a. ¿Existen diferencias entre los tratamientos?

En las gráficas presentadas para representar los datos de tratamientos según tres tipos de veneno, se logra observar que, si existen diferencias entre los diferentes tratamientos y entre el mismo tipo de tratamiento para los distintos venenos.

b. ¿Qué tratamiento afectó en mayor medida la supervivencia?

Se observa que para los tres tipos de venenos, el tratamiento que más influyó en el tiempo de vida es el Tratamiento A. Este tratamiento registra con mayor frecuencia los menores tiempos de vida registrados.

c. ¿Hay diferencias entre los venenos? ¿Qué veneno afectó en menor medida la supervivencia?

De acuerdo con el histograma de distribución de los datos, el veneno III tiene todos los tratamientos concentrados en un lapso de tiempo de vida de 0.17 a 0.375 aproximadamente. Mientras que, los venenos I y II tienen el valor de tiempo de vida más variable.

```
surv <- read.csv("survival.tsv",sep="")
surv
```


	Tratamiento	Veneno	Supervivencia
1	A	I	0.31
2	A	I	0.45
3	A	I	0.46
4	A	I	0.43
5	A	II	0.36
6	A	II	0.29
7	A	II	0.40
8	A	II	0.23
9	A	III	0.22
10	A	III	0.21
11	A	III	0.18
12	A	III	0.23
13	B	I	0.82
14	B	I	1.10
15	B	I	0.88
16	B	I	0.72
17	B	II	0.92
18	B	II	0.61
19	B	II	0.49
20	B	II	1.24
21	B	III	0.30
22	B	III	0.37
23	B	III	0.38
24	B	III	0.29
25	C	I	0.43
26	C	I	0.45

27	C	I	0.63
28	C	I	0.72
29	C	II	0.44
30	C	II	0.35
31	C	II	0.31
32	C	II	0.40
33	C	III	0.23
34	C	III	0.25
35	C	III	0.24
36	C	III	0.22
37	D	I	0.45
38	D	I	0.71
39	D	I	0.66
40	D	I	0.62
41	D	II	0.56
42	D	II	1.02
43	D	II	0.71
44	D	II	0.38
45	D	III	0.30
46	D	III	0.36
47	D	III	0.31
48	D	III	0.33

```
graf_surv <- ggplot(data=surv,aes(x=Supervivencia,fill=Tratamiento))+
  geom_histogram()+
  facet_wrap(~Veneno)+
  labs(x="Tiempo de Supervivencia", y="Frecuencia",fill="Tratamiento", title="Histograma de Distribución")
  theme(plot.title = element_text(hjust=0.5))
```


```
graf_surv
```

``stat_bin()` using `bins = 30`. Pick better value with `binwidth`.`



```
boxplot_surv<- ggplot(surv, aes(x = Tratamiento, y = Supervivencia, fill = Veneno)) +
  geom_boxplot(color='black') +
  geom_jitter(width = 0.05, height = 0.05) +
  ylab("Tiempo de Supervivencia") +
  xlab("Tratamiento") +
  theme_bw()+
  labs(title="BoxPlot Supervivencia según Veneno y Tratamiento",fill="Veneno")+ theme(plot.title = element_text(h
```

boxplot_surv




```

densidad_surv <- ggplot(surv, aes(Supervivencia, fill=Tratamiento)) +
  facet_wrap(vars(Veneno)) +
  geom_density() +
  labs(x = 'Tiempo de Supervivencia', y = 'Frecuencia', fill="Tratamiento", title = "Gráfica de Densidad Supervivencia") +
  theme_bw()

```

```
theme(plot.title = element_text(hjust=0.5))
densidad_surv
```



Se plantea una hipótesis nula para cada factor y la interacción entre estos.

Veneno:

H_0 : El promedio de tiempo de supervivencia de cada veneno es el mismo. H_a : Al menos uno o más de las medias del tiempo de supervivencia de cada veneno es diferente.

Tratamiento:

H_0 : El promedio de tiempo de supervivencia de cada tratamiento es el mismo. H_a : Al menos uno o más de las medias del tiempo de supervivencia de cada tratamiento es diferente.

Interacción entre los Venenos y los Tratamientos:

H_0 : El promedio de tiempo de supervivencia de cada veneno entre los diferentes tratamientos es el mismo. H_a : Al menos uno o más de las medias del tiempo de supervivencia de cada veneno entre los diferentes tratamientos es diferente.

El nivel de significancia escogido es de 0.01, ya que este valor es más estricto en rechazar la hipótesis nula, esto con el propósito de tener la mayor seguridad posible de que si se rechaza la hipótesis nula es porque existe una probabilidad muy baja de cometer un error al hacerlo. Por ende, habría mayor certeza de la hipótesis alternativa es verdadera.

Primero se genera el test ANOVA múltiple y sus respectivos chequeos para conocer si cumple las asunciones del test.

```
anova_surv<- aov(data=surv,Supervivencia ~ Tratamiento*Veneno)
summary(anova_surv)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Tratamiento	3	0.9283	0.3094	14.162	2.97e-06 ***
Veneno	2	1.0220	0.5110	23.390	3.10e-07 ***
Tratamiento:Veneno	6	0.2474	0.0412	1.887	0.11
Residuals	36	0.7865	0.0218		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
check_autocorrelation(anova_surv)
```

OK: Residuals appear to be independent and not autocorrelated (p = 0.796).

```
check_normality(anova_surv)
```

Warning: Non-normality of residuals detected (p = 0.001).


```
check_heteroskedasticity(anova_surv)
```

Warning: Heteroscedasticity (non-constant error variance) detected ($p < .001$).

```
plot(check_homogeneity(anova_surv))
```

Homogeneity of Variance (Bartlett Test)


Groups should be evenly spread



```
plot(check_normality(anova_surv),type="density")
```

Normality of Residuals


Distribution should be close to the normal curve



```
plot(check_heteroskedasticity(anova_surv))
```

Homogeneity of Variance

Reference line should be flat and horizontal



De acuerdo con el nivel de significancia elegido no hay homocedasticidad ni normalidad en los residuos. Por tal motivo se realiza la prueba Sheirer Ray Hare, donde el estadístico de prueba es chi-cuadrado.

```
library(rcompanion)
```

Warning: package 'rcompanion' was built under R version 4.4.3

```
library(DescTools)
```

Warning: package 'DescTools' was built under R version 4.4.3

```
library(multcomp)
```

Warning: package 'multcomp' was built under R version 4.4.3

Cargando paquete requerido: mvtnorm

Warning: package 'mvtnorm' was built under R version 4.4.3

Cargando paquete requerido: survival

Cargando paquete requerido: TH.data

Warning: package 'TH.data' was built under R version 4.4.3

Cargando paquete requerido: MASS

Adjuntando el paquete: 'MASS'

The following object is masked from 'package:dplyr':

```
select
```

Adjuntando el paquete: 'TH.data'

The following object is masked from 'package:MASS':

```
geyser
```

```
scheirerRayHare(Supervivencia ~ Veneno * Tratamiento, data = surv)
```

DV: Supervivencia

Observations: 48

D: 0.9988602

MS total: 196

	Df	Sum Sq	H	p.value
Veneno	2	5009.1	25.5858	0.00000
Tratamiento	3	2581.4	13.1853	0.00425
Veneno:Tratamiento	6	288.0	1.4712	0.96138
Residuals	36	1323.0		

Según el test Scheirer-Ray-Hare el efecto del veneno y los tratamientos tiene un efecto sobre la supervivencia de forma separada, ya que se rechazan sus respectivas hipótesis nulas. Por otro lado, el test sugiere que, la interacción entre los diferentes tipos de tratamiento y los distintos venenos no influye en la supervivencia de los sujetos, ya que el valor-p reportado para este caso acepta la hipótesis nula de que el promedio de tiempo de supervivencia de cada veneno entre los diferentes tratamientos es el mismo.

d. ¿Existe interacción? Incluya el Valor-P y el gráfico.

El test Scheirer-Ray-Hare indica que la interacción entre los dos factores no es significativa, es decir que los efectos de un factor no dependen del otro.

```
gra<- ggplot(surv, aes(x = Tratamiento, y = Supervivencia, color = as.factor(Veneno), group = Veneno)) +
  stat_summary(fun = mean, geom = "line", size = 1)
```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.

! Please use `linewidth` instead.

```
stat_summary(fun = mean, geom = "point", size = 3)
```

geom_point: na.rm = FALSE

stat_summary: fun.data = NULL, fun = function (x, ...)

UseMethod("mean"), fun.max = NULL, fun.min = NULL, fun.args = list(), na.rm = FALSE, orientation = NA


position_identity

```
labs(title = "Interacción entre Veneno y Tratamiento",
     x = "Tratamiento", y = "Supervivencia",
```

```
color = "Veneno") +  
theme_minimal()
```

NULL

gra



e. Conclusión biológica.

